

Статистический анализ изменчивости экономических рейтингов компаний

Д.В. Липатов,

магистр, аналитик службы валидации, ООО «Национальные Кредитные Рейтинги»
(e-mail: danchik-lip@mail.ru)

Л.В. Кирьянова,

канд. физ.-мат. наук, доцент, доцент кафедры ВМ, ФГБОУ ВО «НИУ МГСУ» (e-mail: KiryanovaLV@mgsu.ru)

Аннотация. В статье представлены результаты расчета матриц миграции кредитных рейтингов на основе синтетических и реальных данных. Рассматриваются два подхода к расчету, их алгоритмы, сходимость и различия. Верификация сходимости алгоритмов проводилась на малых шагах итерирования. Результаты данной работы могут использоваться для обновления методологий расчета матриц миграции кредитных рейтингов в кредитном рейтинговом агентстве, являться основой для поиска новых методов расчетов матриц миграции.

Abstract. The article presents the results of calculating migration matrices of credit ratings based on synthetic and real data. Two approaches to calculation, their algorithms, convergence and differences are considered. Verification of the convergence of the algorithms was carried out at small iteration steps. The results of this work can be used to update the methodologies for calculating migration matrices of credit ratings in a credit rating agency, and serve as the basis for finding new methods for calculating migration matrices.

Ключевые слова: матрицы миграции кредитных рейтингов, эконометрика, кредитные рейтинги, марковский процесс с априорным распределением Дирихле, марковский процесс с непрерывным временем.

Keywords: credit rating migration matrices, econometrics, credit ratings, discrete time Markov process, continuous time Markov process.

Отрасль кредитных рейтинговых агентств в России уже стала частью экономической жизни страны. Оценке и прогнозированию вероятностей, составляющих так называемые матрицы миграции кредитных рейтингов посвящены, в частности, статьи [1] и [2]. В работах [1], [3] и [4] рассматривались два подхода для вычисления матрицы переходных вероятностей кредитных рейтингов. На основе синтетических и реальных данных из открытых источников было продемонстрировано преимущество модели с непрерывным временем. В работе [2] были использованы оба подхода, рассмотрены достоинства и недостатки каждого из них. Однако в общем случае при слишком маленьком шаге интерполяции, например 1 день или 1 месяц размер исходного статистического материала увеличивается, а вместе с ним и увеличивается время расчета, причем увеличивается практически линейно, что создает определенные трудности при вычислении.

Для задач, когда исходные данные имеют неоднородности по времени, то есть нет возможности однозначно итерироваться статистические данные с равным шагом без дополнительных преобразований (набор данных разбит неравномерно) выбор модели с непрерывным временем однозначен. Однако при возможности разбиения на равные шаги есть более быстрые аналоги. Одним из таких является построение матрицы переходных вероятностей с использованием, в качестве априорного, распределения Дирихле [5]. Данный вид распределения хорошо подходит для получения оценок переходных вероятностей и дальнейшего построения матрицы, так как он, согласно [6]:

1) позволяет избегать появления ненулевых вероятностей в тех местах матрицы миграции, где по смыслу переход возможен;

2) гарантирует свойство стохастичности для матрицы миграции (все элементы матрицы

неотрицательны и сумма элементов каждой строки равна 1);

3) является достаточным гибким из-за возможности выбора априорных параметров;

4) удобен для сэмплирования и регуляризации при применении методов машинного обучения.

Отметим, что в общем случае, модель с дискретным временем может дать нулевые оценки, если число переходов N_{ij} из состояния i в состояние j мало или равно нулю. Байесовский подход с априорным распределением Дирихле и неинформативным априором $\alpha_i = 1$ (что соответствует равномерному распределению) позволяет избежать таких ситуаций [7]. Тогда математическое ожидание для вероятностей апостериорного распределения имеет вид:

$$M[P_{ij} | N] = \frac{N_{ij} + \alpha_i}{\sum (N_{ij} + \alpha_i)}$$

Для сравнения непрерывного метода и дискретного байесовского, рассмотрим пример, аналогичный тому, что был приведен в работе [1], [3]. Матрица переходных вероятностей, полученная с помощью непрерывной модели для трех состояний (AAA-AA, A-BBB и D) имеет вид:

$$P = \begin{pmatrix} 0,9091 & 0,0862 & 0,0047 \\ 0,0892 & 0,8168 & 0,0940 \\ 0 & 0 & 1 \end{pmatrix}.$$

Матрица переходных вероятностей с применением Байесовского подхода и выбранным неинформативным априором $\alpha_i = 1$ имеет вид:

$$P = \begin{pmatrix} 0,9057 & 0,0628 & 0,0315 \\ 0,0587 & 0,8819 & 0,0594 \\ 0,3306 & 0,3334 & 0,3360 \end{pmatrix}.$$

Очевидно, что в поглощающем состоянии D вероятности распределены почти равномерно, согласно априорному распределению. Такой эффект проявляется и в любых других состояниях, когда фактических переходов не наблюдалось вообще или наблюдалось крайне мало. В таком случае, представляется целесообразным добавить как штраф на редкие переходы, так и штраф на слишком большие переходы согласно формуле:

$$\zeta_{ij} = \begin{cases} |r_j - r_i|, & r_j \neq r_i \\ \theta, & r_j = r_i \end{cases}, \quad \theta \in (0, \infty).$$

В этом случае частоты могут быть пересчитаны по формуле:

$$N_{ij}^* = \frac{N_{ij} + 1}{\zeta_{ij}}.$$

Если принять значение параметра $\theta = 10$, то матрица переходных вероятностей будет иметь вид:

$$P = \begin{pmatrix} 0,9054 & 0,0838 & 0,0108 \\ 0,0790 & 0,8421 & 0,0789 \\ 0,0118 & 0,0476 & 0,9406 \end{pmatrix}.$$

Эта матрица довольно близка (поэлементно) к той, что получена в модели с непрерывным временем. (Если состояние D является поглощающим, то можно положить значение вероятности перехода из D в D равной единице, тогда все остальные вероятности равны нулю.)

Подбирая параметр θ , матрицу переходных вероятностей можно еще больше приблизить к той, что получается при расчете через модель с непрерывным временем.

Для применения байесовского подхода в дискретной модели, введем следующие ограничения для работы с исходными данными:

1) Для каждого нового среза S_n с шагом h может существовать состояние, в которое перешел объект на предыдущем срезе S_{n-1} , в противном случае данный срез пропускается и не учитывается в усреднении.

2) Если разница между датой предыдущего состояния и датой начала среза больше 1 года (независимо от шага h), то такой срез не учитывается в усреднении.

3) Если объект переходит в состояние дефолта (рейтинг D), то вернуться из него в любое другое состояние он не может (исключение для процесса с непрерывным временем, так как внутри интервала такие переходы могут быть, если на начало интервала объект находится в состоянии D, то такой интервал пропускается).

В качестве примера возьмем набор данных одного кредитного рейтингового агентства. Произведем ресемплинг данных, и учитывая гипотезы и алгоритм каждого подхода, найдем матрицу переходных состояний с шагом 1 месяц.

Рассмотрим две сферы деятельности компаний (группа 1 и группа 2). Для каждой из группы вычислим матрицу переходных вероятностей.

Матрица переходных вероятностей для модели с непрерывным временем для группы 1:

Таблица 1

Матрица переходных вероятностей для модели с непрерывным временем для группы 1

	AAA-AA	AA-A	A-BBB	BB	B	CCC-C	D
AAA-AA	0,956	0,038	0,006	0,000	0,000	0,000	0,000
AA-A	0,046	0,894	0,051	0,006	0,003	0,000	0,000
A-BBB	0,003	0,041	0,917	0,027	0,005	0,001	0,005
BB	0,000	0,004	0,051	0,902	0,027	0,004	0,012
B	0,000	0,000	0,001	0,050	0,897	0,013	0,039
CCC-C	0,000	0,000	0,000	0,003	0,069	0,689	0,240
D	0,000	0,000	0,000	0,006	0,006	0,000	0,988

Матрица переходных вероятностей для
Байесовского подхода для группы 1:

Таблица 2

Матрица переходных вероятностей для Байесовского подхода для группы 1

	AAA-AA	AA-A	A-BBB	BB	B	CCC-C	D
AAA-AA	0,939	0,053	0,005	0,001	0,001	0,001	0,001
AA-A	0,059	0,865	0,067	0,005	0,002	0,001	0,001
A-BBB	0,002	0,050	0,908	0,033	0,004	0,001	0,002
BB	0,001	0,003	0,056	0,899	0,030	0,005	0,006
B	0,002	0,002	0,003	0,068	0,871	0,027	0,027
CCC-C	0,005	0,006	0,008	0,012	0,074	0,641	0,253
D	0,001	0,002	0,002	0,005	0,008	0,008	0,974

Матрица переходных вероятностей для
модели с непрерывным временем для группы 2:

Таблица 3

Матрица переходных вероятностей для модели с непрерывным временем для группы 2

	AAA-AA	AA-A	A-BBB	BB	B	CCC-C	D
AAA-AA	0,968	0,028	0,003	0,000	0,000	0,000	0,000
AA-A	0,048	0,903	0,043	0,005	0,000	0,000	0,000
A-BBB	0,001	0,041	0,938	0,012	0,000	0,001	0,007
BB	0,000	0,007	0,030	0,921	0,017	0,009	0,015
B	0,000	0,000	0,001	0,047	0,894	0,024	0,033
CCC-C	0,002	0,002	0,008	0,002	0,000	0,531	0,456
D	0,006	0,007	0,031	0,006	0,000	0,000	0,949

Матрица переходных вероятностей для
Байесовского подхода для группы 2:

Таблица 4

Матрица переходных вероятностей для Байесовского подхода для группы 2

	AAA-AA	AA-A	A-BBB	BB	B	CCC-C	D
AAA-AA	0,955	0,038	0,004	0,001	0,001	0,001	0,001
AA-A	0,056	0,883	0,056	0,003	0,001	0,001	0,001
A-BBB	0,001	0,047	0,932	0,015	0,001	0,001	0,003
BB	0,001	0,004	0,032	0,917	0,029	0,010	0,007
B	0,003	0,004	0,006	0,066	0,845	0,055	0,022
CCC-C	0,009	0,011	0,015	0,022	0,043	0,473	0,428
D	0,003	0,003	0,013	0,006	0,005	0,009	0,961

Анализируя попарные компоненты каждой матрицы переходных вероятностей можно заметить, что отклонения между матрицами непрерывной и дискретного байесовской моделей не такие существенные.

Для оценки качества рассмотрим две метрики: $RMSE$ (корень среднеквадратичной ошибки) и MAE (средняя абсолютная ошибка), которые отобразят реакцию на выбросы и относительную стабильность матриц:

Для группы 1: $RMSE = 2.86$; $MAE = 1.59$.

Для группы 2: $RMSE = 2.71$; $MAE = 1.56$.

Аналогично рассмотрим относительную стабильность приведенных оценок – отклонение главных диагоналей:

Для группы 1:

$RMSE_{\text{главной диагонали}} = 6.48$.

$MAE_{\text{главной диагонали}} = 5.06$.

Для группы 2:

$RMSE_{\text{главной диагонали}} = 6.03$.

$MAE_{\text{главной диагонали}} = 5.30$.

Так же хорошей метрикой качества является расчет параметра точности *assurasy*. В нашем случае имеется 7 классов, по которым необходимо рассчитать данный параметр и оценить качество прогнозирования. Будем рассчитывать прогноз на 1 год, 2 года, 3 года и 4 года:




Рис. 1. Вычисление параметра многоклассовой классификации *assigasu* для прогнозирования на горизонте 1 год, 2 года, 3 года и 4 года.

Из данного изображения можно увидеть, что отклонения для каждого из методов составляют не более 5%, что в целом согласуется с расчетом метрики *MAE*. Однако самые высокие показатели прогноза держатся на первых двух годах, что свидетельствует о том, что данные методы являются менее устойчивые к прогнозированию на более длительный срок. Это и логично, так как

в силу специфики данных подходов, а также малости изменчивости данных (относительная стабильность рейтингов), прогнозирование на длительные периоды требует экспертной оценки, а также более современных методов машинного обучения. Тем не менее результаты довольно впечатляющие.




Рис. 2. Вычисление параметра многоклассовой классификации *assigasu* для прогнозирования на горизонте 1 год, 2 года, 3 года и 4 года.

Данное изображение так же демонстрирует значения *assigasu*, но здесь добавлен бейзлайн (метод прогнозирования, при котором предполагается, что значения не изменяются вовсе после последнего наблюдения). Очевидно, что здесь модель должна предсказывать либо совсем плохо, либо как случайность (попадем в

класс или нет). Таким образом очевидно, что любой из методов так или иначе превосходит по способностям прогнозирования метод бейзлайна.

Таким образом, для каждой группы отклонения довольно близкие, *MAE* можно интерпрети-

ровать как процентное отклонение значений, а *асигура* является метрикой классификации. В таком случае эти показатели можно отнести к погрешностям при использовании априорное распределения Дирихле.

Далее обратимся к преимуществам применения Байесовского подхода с априорным распределением Дирихле, относительно используемого машинного времени. Для этого, также, как и для модели с непрерывным временем, было измерено время выполнения расчетов для разного

количества данных и затем проведено усреднение полученных величин (запуск производился по 50 раз). На рисунке 1 представлена полученная эмпирическая зависимость времени выполнения вычислений от объема данных двумя разными методами: при непрерывном подходе (синий цвет) и при дискретном подходе с использованием априорного распределения Дирихле (зеленый цвет).




Рис. 3. Зависимость времени вычислений от объема данных для двух моделей: непрерывной и дискретной с использованием байесовского подхода и априорного распределения Дирихле.

Итак, в данной работе были рассмотрены два метода для анализа матриц миграций на основе реальных данных кредитного рейтингового агентства за большой временной интервал.

Для оценки качества двух моделей использовался критерий *RMSE / MAE*, анализ результата применения данного критерия позволяет сделать вывод о сходимости двух реализаций друг к другу.

Результаты данной работы позволяют при анализе и оценке вероятностей в матрицах миграции заменить точный, но затратный по производительности подход с непрерывным временем на не менее точный, но в разы производительнее Байесовских подход с априорным распределением Дирихле.

В дальнейшем возможно применение методов машинного обучения для подбора значений гиперпараметра θ (его можно рассматривать в качестве коэффициента самоперехода), необходимого для корректировки сходимости Байесовского подхода к подходу с непрерывным временем.

Библиографический список:

1. David Lando Analyzing rating transitions and rating drift with continuous observations // Journal of Banking & Finance. - 2002. - №26. - С. 423-444

2. Л.В. Кирьянова, Д.В. Липатов. Статистическое исследование изменения рейтинга компаний, занимающихся экономической деятельностью. Экономика и предпринимательство. № 8; 2024 г., стр 1286 - 1290

3. David Lando Credit Risk Modeling: Theory and Applications. - 1 изд. - United Kingdom: Princeton University Press, 2004. - 329 с.

4. Muliaman D Hadad, Wimboh Santoso, Bagus Santoso, Dwityapoetra Besar, Ita Rulina Rating migration matrices: empirical evidence in Indonesia // IFC Bulletin. - 2009. - №31. - С. 260-276.

5. Andrew Gelman, John B. Carlin, Hal S. Stern, David B. Dunson, Aki Vehtari, Donald B. Rubin. Bayesian Data Analysis // URL: <https://sites.stat.columbia.edu/gelman/book/>

6. Thomas S. Ferguson A. Bayesian Analysis of Some Nonparametric Problems // URL: <https://projecteuclid.org/journals/annals-of-statistics/volume-1/issue-2/A-Bayesian-Analysis-of-Some-Nonparametric-Problems/10.1214/aos/1176342360.full>

7. Bayesian nonparametric learning of complex dynamical phenomena// Fox, Emily Beth. URL: <https://dspace.mit.edu/handle/1721.1/55111>.

Дата поступления рукописи в редакцию
02.05.2025

Дата принятия рукописи в печать
06.05.2025